

Optimización de Portafolio en Python: Markowitz, Restricciones y Análisis de Sensibilidad

Arnau Sastre

[linkedin.com/in/arnausastre](https://www.linkedin.com/in/arnausastre)

August 9, 2025

Abstract

Este artículo presenta un sistema completo de optimización de portafolio basado en el modelo clásico de Markowitz, implementado con `cvxpy` y datos reales obtenidos mediante `yfinance`. Se construyen y comparan carteras óptimas bajo distintos criterios (mínima varianza, máxima rentabilidad para una volatilidad objetivo) e incluyendo restricciones prácticas (sin cortos, límites por activo). Además, se realiza análisis de sensibilidad para evaluar el impacto de cambios en las expectativas de retorno. El enfoque está orientado a entornos profesionales como fintechs, gestores de activos e inversores cuantitativos.

1 Introducción

La optimización de portafolios permite asignar capital entre activos para equilibrar riesgo y retorno. El marco de Markowitz modela este equilibrio como un problema convexo sobre la matriz de covarianzas de retornos. En este trabajo se implementa un flujo reproducible en Python que:

- Descarga precios ajustados de activos reales (AAPL, MSFT, AMZN, GOOGL, META) y calcula retornos.
- Estima métricas anuales: retornos esperados, volatilidades y covarianzas.
- Resuelve carteras óptimas con `cvxpy` bajo múltiples escenarios y restricciones.
- Analiza sensibilidad ante cambios en expectativas de retorno.

2 Formulación del modelo

Sea $\mathbf{w} \in \mathbb{R}^n$ el vector de pesos, $\boldsymbol{\mu} \in \mathbb{R}^n$ los retornos esperados y $\Sigma \in \mathbb{R}^{n \times n}$ la matriz de covarianza. Definimos:

$$\text{Retorno}(\mathbf{w}) = \boldsymbol{\mu}^\top \mathbf{w}, \quad \text{Riesgo}(\mathbf{w}) = \sqrt{\mathbf{w}^\top \Sigma \mathbf{w}}$$

Mínima varianza

$$\begin{aligned} \min_{\mathbf{w}} \quad & \mathbf{w}^\top \Sigma \mathbf{w} \\ \text{s.a.} \quad & \mathbf{1}^\top \mathbf{w} = 1, \\ & \mathbf{w} \in \mathcal{C} \end{aligned}$$

donde $\mathcal{C}$ captura las restricciones (p.ej., $w_i \geq 0$, cotas $0 \leq w_i \leq b_i$).

Máximo retorno para una volatilidad objetivo

$$\begin{aligned} \max_{\mathbf{w}} \quad & \boldsymbol{\mu}^\top \mathbf{w} \\ \text{s.a.} \quad & \mathbf{w}^\top \Sigma \mathbf{w} \leq \sigma_{\text{obj}}^2, \\ & \mathbf{1}^\top \mathbf{w} = 1, \\ & \mathbf{w} \in \mathcal{C} \end{aligned}$$

Ratio de Sharpe (para evaluación)

$$\text{Sharpe}(\mathbf{w}) = \frac{\boldsymbol{\mu}^\top \mathbf{w} - r_f}{\sqrt{\mathbf{w}^\top \Sigma \mathbf{w}}}$$

con r_f tipo libre de riesgo (opcional, se asume 0 si no se especifica).

3 Datos y preprocesado

Con `yfinance` se descargan precios ajustados diarios de AAPL, MSFT, AMZN, GOOGL, META. Se calculan:

- Retornos logarítmicos o simples diarios.
- Media de retornos diaria y su anualización (factorización por 252).
- Covarianza diaria y su anualización.

4 Optimización con restricciones prácticas

El conjunto de restricciones consideradas incluye:

- **Sin cortos:** $w_i \geq 0$.
- **Límites por activo:** $0 \leq w_i \leq b_i$ (p.ej., $b_i \leq 0.4$).
- **Presupuesto:** $\mathbf{1}^\top \mathbf{w} = 1$.

Los problemas se resuelven con `cvxpy`, utilizando solvers compatibles (p.ej., ECOS / OSQP). Para carteras con retorno objetivo, se añade la restricción $\boldsymbol{\mu}^\top \mathbf{w} \geq \rho$ o, alternativamente, una cota a la varianza para maximizar retorno.

5 Análisis de sensibilidad

Se evalúa la estabilidad de la solución ante cambios en $\boldsymbol{\mu}$. En particular, se simula un aumento/disminución en la expectativa de retorno de AAPL:

$$\mu'_{\text{AAPL}} = \mu_{\text{AAPL}} + \Delta$$

y se resuelve nuevamente el problema para comparar la nueva asignación $\mathbf{w}'$ y su impacto en retorno, riesgo y Sharpe.

6 Métricas de evaluación

Para cada solución se reporta:

- **Retorno esperado anual:** $\mu^\top \mathbf{w}$.
- **Volatilidad anual:** $\sqrt{\mathbf{w}^\top \Sigma \mathbf{w}}$.
- **Ratio de Sharpe:** siguiendo la definición anterior.

7 Resultados

A modo de *ejemplo técnico reproducible* (extraído del `notebook` del proyecto), una solución posible con restricciones prácticas puede verse así:

Pesos:

AAPL 0.1873 MSFT 0.2054 AMZN 0.2281 GOOGL 0.1984 META 0.1808

Métricas:

Retorno 0.2273 Volatilidad 0.3149 Sharpe 0.6891

En el análisis de sensibilidad, al modificar la expectativa de retorno de AAPL y recomputar la solución, se observa el ajuste automático en los pesos y en las métricas agregadas del portafolio (detalles en el `notebook`).

8 Aplicación empresarial

El sistema es aplicable a:

- **Robo-advisors:** asignación sistemática bajo reglas y límites regulatorios.
- **Gestión de carteras:** construcción de mandatos *long-only* con límites por activo.
- **Consultoría de riesgo:** evaluación de sensibilidad y escenarios *what-if*.
- **Equity research:** soporte cuantitativo para presentaciones internas y *backtesting* de tesis.

9 Tecnologías utilizadas

- Python (`numpy`, `pandas`, `cvxpy`)
- `yfinance` para datos históricos reales
- Enfoque numérico (sin visualizaciones, centrado en lógica técnica)

10 Estructura del proyecto

```
.
Markowitz.ipynb      # Notebook ejecutable con la optimización
README.md             # Instrucciones de uso y personalización
```

11 Conclusiones

Se ha implementado un marco robusto para la optimización de portafolios que combina el modelo de Markowitz, restricciones prácticas y análisis de sensibilidad. La solución es reproducible, extensible y aplicable en entornos profesionales, permitiendo comparar escenarios y tomar decisiones de inversión con criterios cuantitativos.

Cómo usar

Abra el **notebook** en Google Colab o su entorno local, ejecute el flujo paso a paso y personalice el universo de activos, el retorno objetivo y las restricciones según sus necesidades.

Contacto

Para más información o implementación de este modelo, puede contactarme vía **LinkedIn** o consultar otros proyectos en mi **GitHub**.